

САДРЖАЈ

1. УВОД	1
2. РЕЛЕВАНТНА ИСТРАЖИВАЊА	3
3. ВЕШТАЧКА ИНТЕЛИГЕНЦИЈА	4
4. МАШИНСКО УЧЕЊЕ	6
4.1 Подела машинског учења	6
4.2 Апликације	7
5. КЛАСИФИКАЦИОНИ МОДЕЛИ У НАДГЛЕДАНОМ УЧЕЊУ	8
5.1 Логистичка регресија	8
5.2 К најближих суседа	10
5.3 Стабло одлуке	12
5.4 Насумична шума	13
5.5 Метода потпорних квадрата	14
6. ОПИС СКУПА ПОДАТАКА	16
7. ПРОЦЕС ОБРАДЕ ПОДАТАКА И ИЗГРАДЊЕ МОДЕЛА	17
8. ПРЕДОБРАДА ПОДАТАКА	18
8.1 Идентификација и обрада недостајућих вредности	18
8.2 Детекција аномалија	19
8.3 Визуелизација података	21
8.4 Конверзија категоријских података у нумеричке вредности	23
8.5 Балансирање података	24
9. ПОДЕЛА ПОДАТАКА НА ТРЕНИНГ И ТЕСТ СЕТ	24
10. СТАНДАРДИЗАЦИЈА ПОДАТАКА	25
11. ИЗГРАДЊА МОДЕЛА И АНАЛИЗА РЕЗУЛТАТА	25
11.1 Изградња модела	25
11.2 Анализа резултата	27
12. ЗАКЉУЧАК	30

1. УВОД

Мождани удар је један од водећих узрока смртности и инвалидитета на глобалном нивоу, а његов снажан утицај на појединца и друштво чини га озбиљним здравственим проблемом. Према подацима Светске организације за мождани удар, сваке године 13 милиона људи доживи мождани удар, а око 5.5 милиона случајева заврши се смртним исходом [9].

Мождани удар настаје када крвни суд који доводи кисеоник и хранљиве материје до мозга постане зачепљен угрушком или пукне (руптира) [17]. Као последица тога, одређени део мозга остаје без неопходног дотока крви и кисеоника, што доводи до одумирања можданих ћелија у захваћеном подручју. Уколико настаје услед блокаде протока крви ка мозгу због угрушка, зове се исхемијски мождани удар, а ако настаје руптуром крвног суда назива се хеморагијски мождани удар [16]. Постоји и мождани удар који је узрокован привременим угрушком и зове се пролазни исхемијски напад. У случају можданог удара, компјутеризована томографија (енгл. *CT*) омогућава прецизну дијагнозу, док магнетна резонанца (енгл. *MRI*) представља најпоузданију дијагностичку методу када је у питању исхемијски мождани удар.

Симптоми можданог удара могу бити различити, од благе слабости до потпуне парализе или губитка осећаја на једној страни лица или тела. Додатни знаци могу обухватити наглу и интензивну главоболју, потешкоће са видом на једном или оба ока, изненадну слабост, као и проблеме са говором или разумевањем говора.

Различити фактори попут гојазности, прекомерног или учесталог конзумирања алкохола, употребе различитих илегалних супстанци попут кокаина и метамфетамина, могу допринети повећању ризика од можданог удара. Са медицинске стране висок крвни притисак, дијабетес, повишен холестерол, срчане болести, пушење (активно или пасивно), као и лична породична историја можданог удара, пролазног исхемијског напада или инфекција *COVID-19* представљају значајне факторе ризика [18]. Постоје и фактори ризика на које се не може утицати, као што су старост и пол. Старост је један од кључних фактора, особе старије од 55 година имају знатно веће шансе да доживе мождани удар у поређењу са млађима. Пол је такође битан фактор. Мушкарци статистички чешће доживе мождани удар, док га жене обично доживе у старијем животном добу и суочавају се са већим ризиком од смртог исхода.

Последице након можданог удара могу бити различите у зависности од његове тежине [19]. Почевши од физичких промена попут бола, проблема са гутањем, константног осећаја умора, смањене могућности за физичком активности, па све до емотивних промена као што су депресија, анксиозност и промене у личности и понашању. Такође утиче на когнитивне способности (вештине размишљања и памћења). Може доћи до губитка краткорочног памћења, концентрације, оријентације, као и способности планирања и решавања проблема.

Поред ових промена ризик од новог možданог удара значајно је повећан код особа које су већ претрпеле један. Због тога неопходна је терапија лековима који циљају на смањење фактора ризика. Може укључивати лекове за смањење крвног притиска, анти тромбоцитне лекове за смањење ризика од настанка крвног угрушка или лекове за контролу холестерола. Такође важно је да пацијент уведе промене у стилу живота, ради побољшања здравља. То укључује промену начина исхране, редовно вежбање, престанак пушења и конзумирања алкохола.

Технологија машинског учења има значајну улогу у доношењу клиничких одлука и у раној детекцији здравствених ризика, укључујући možдани удар. Алгоритми машинског учења могу проценити вероватноћу možданог удара код појединачца анализом и идентификовањем образаца и веза у великим скуповима података о пацијентима.

Циљ овог рада је развијање различитих модела машинског учења за предикцију možданог удара и кроз анализу перформанси утврдити који од њих пружа највиши ниво поузданости. У другом поглављу разматрају се релевантна истраживања на тему предикције možданог удара. Треће поглавље представља увод у основне концепте вештачке интелигенције, док се четврто поглавље бави детаљнијим описом машинског учења, његове поделе и примене у различитим областима. Пето поглавље фокусира се на теоријски опис класификационих модела у надгледаном учењу, као што су логистичка регресија, К најближих суседа, стабло одлуке, насумична шума и метода потпорних вектора, који су примењени у овом раду за предикцију možданог удара. Шесто поглавље садржи опис скупа података и њихову припрему за моделовање. Седмо поглавље описује процес обраде података и изградње модела, где је нагласак на различитим корацима који су предузети како би се подаци припремили за анализу и изградњу модела. Осмо поглавље детаљно разматра предобраду података, укључујући идентификацију и обраду недостајућих вредности, детекцију аномалија, визуелизацију података, конверзију категоријских података у нумеричке вредности и балансирање података. У деветом поглављу обрађује се подела скупа података на тренинг и тест сетове како би се обезбедила објективност у процени модела. Десето поглавље се фокусира на стандардизацију података, што је кључни корак у обради података пре изградње модела.

Након предобrade података, у једанаестом поглављу је представљена изградња модела и анализа резултата. Овде се разматрају различити класификациони модели и њихове перформансе, уз циљ да се утврди који модел најбоље предвиђа možдани удар на основу расположивих података. Тиме ће се на крају добити јасна слика о томе који приступ машинском учењу даје најпоузданије резултате за предикцију možданог удара.

2. РЕЛЕВАНТНА ИСТРАЖИВАЊА

Коришћењем различитих алгоритама машинског учења, у протеклих неколико деценија, спроведен је значајан број истраживања како би се побољшала брзина дијагностификовања можданог удара.

У једном од истраживања под називом „*Detecting risk factor of stroke disease from social media using machine learning techniques*” [14] коришћењем података са друштвених мрежа научници су пронашли начин за идентификацију симптома повезаних са можданим ударом и пронашли превентивне мере против можданог удара. Користили су спектралну кластеризацију како би поделили твитове на основу садржаја. За екперимент коришћени су следећи модели: *Ten-fold cross validation Naive Bayes*, *SVM* и *Probability Neural Network (PNN)*. *PNN* је имао најбољу тачност од 89.9%. [9]

У научном раду под називом „*Detection of stroke disease using machine learning algorithms*” [12] примењена су четири алгорита машинског учења *Naive Bayes*, *J48*, *KNN* и *Random forest*. *Naive Bayes* имао је најмању тачност од 85.6%, док су остали имали тачност од 99.8%.

„*Analyzing the performance of stroke prediction using ML classification algorithms*” [13] је истраживање у којем је употребљена логистичка регресија, *Naive Bayes*, *KNN*, *Decision Tree*, *SVM* и *Random forest*, где *Naive Bayes* са тачношћу од 82% предњачи у односу на остале моделе.

3. ВЕШТАЧКА ИНТЕЛИГЕНЦИЈА

Вештачка интелигенција (AI – Artificial intelligence) је област рачунарства која се бави развојем рачунарских система способних за обављање задатака који су историјски захтевали људску интелигенцију, као што су резонување, доношење одлука или решавање проблема [1]. То је напредна технологија која има утицај у готово свакој области, било да је реч о пословању, ваздухопловству или здравственим системима. Основни циљ AI је да обезбеди транспарентније, интерпретабилније и објашњивије системе који могу помоћи у успостављању боље опремљеног система, уз помоћ области као што су математика (која се користи за развој алгоритама), биологија, психологија, неурологија (за проучавање људског ума и његовог понашања), статистика (за обраду великих података) и подразумевано рачунарство (за покретање алгоритама). Вештачка интелигенција према својим способностима [1] може да се класификује у три различита типа:

- 1) **Слаба или уска AI** (енгл. Artificial Narrow Intelligence - ANI) – Систем који може аутономно да обавља задатке, уз дефинисан уски скуп инструкција. Има веома ограничену функционалност и ефикасан је у својим специфичним доменима, али нема способност генерализације или решавања проблема изван области за коју је дефинисан [2]. Представља најраспрострањенију врсту AI. Неки примери су Apple Siri, Alexa, Google Assistant,...
- 2) **Општа AI** (енгл. Artificial General Intelligence - AGI) – Ови системи су способни да самостално развијају више вештина и праве везе и генерализације између области, масовно смањујући време потребно за одлуку. Циљ опште AI је да учи и примењује стечена знања на нове ситуације, као и човек, а с обзиром да недостаје свеобухватно знање о функционалности људског мозга, ова врста AI је и даље у фази развоја..
- 3) **Суперинтелигенција** (енгл. Artificial Super Intelligence – ASI) – Представља хипотетичку форму вештачке интелигенције. Теоријски би могла да опонаша људску мултидимензионалну интелигенцију и буде боља у свему што ради због своје проширене меморије, брже обраде и анализе података, као и способности доношења одлука [2].

Према функционалности вештачка интелигенција [1] може да се класификује према следећим типовима:

- 1) **Реактивне машине** (енгл. Reactive machines) – Најранији и најосновнији облик AI система са ограниченим капацитетом. Користе само аутоматско реаговање на ограничен скуп улаза тј. немају способност памћења или коришћења претходно стечених искустава за доношење одлука. Познат пример реактивне AI машине је IBM – ов Deep Blue, шаховски програм који је 1997. године победио светског шампиона Гарија Каспарова. Програм анализира шаховску таблу и бира најбоље потезе на основу тренутне ситуације.
- 2) **Ограничено памћење** (енгл. Limited Memory) – Машине са ограниченим памћењем су машине које поседују могућности потпуно реактивних машина и способне су да уче из историјских података како би доносили одлуке. Велики број


постојећих апликација припада овој категорији AI. На пример, AI за препознавање слика обучава се коришћењем великог броја слика и њихових ознака, како би разумео садржај представљене слике и обележава нову слику на основу стеченог искуства. Још један пример су самовозећи аутомобили, који могу да чувају информације попут брзине, удаљености, ограничења који су потребни за навигацију.

- 3) **Теорија ума** (енгл. Theory of Mind) – Представља следећи ниво AI система који би требало да разуме људске емоције, уверења, намере, као и друге менталне процесе и да ради у складу са њима. Ова врста AI је тренутно у фази развоја.
- 4) **Самосвест** (енгл. Self-awareness) – Представља врхунац развоја AI система. Ова врста AI неће бити способна само да разуме емоције код оних са којима комуницира, већ ће имати и способност да препозна своје постојање, разуме своје стање и доноси независне одлуке на основу самосвести. Самосвесна AI тренутно представља теоријски концепт.

Појава вештачке интелигенције омогућила је развој напредних техника за решавање проблема из свакодневног живота. Два главна подскупа вештачке интелигенције (Слика 1) су:

- Машинско учење (енгл. Machine learning)
- Дубоко учење (енгл. Deep learning)

Машинско учење сматра се подскупом вештачке интелигенције, док се дубоко учење сматра подскупом машинског учења. Машинско учење је способност машина да аутоматски уче из података и алгоритама, користећи основне компоненте вештачке интелигенције [3]. Дубоко учење користи вештачке неуронске мреже (ANN – Artificial Neural Network) инспирисане људским мозгом. Користе неуронске мреже за екстракцију апстрактних карактеристика из података, што потенцијално доводи до боље перформансе у поређењу са машинским учењем и често може да пружа снажније репрезентације [3].



Слика 1. Подскупови вештачке интелигенције [34]

4. МАШИНСКО УЧЕЊЕ

Машинско учење, као подобласт вештачке интелигенције, омогућавајући машинама да уче из података и временом функционишу све ефикасније, постаје све важније у нашем друштву. Аутоматизацијом рутинских задатака, машинско учење омогућава људима да се усмере на иновативније пројекте и развијање нових стратегија које унапређују пословање и свакодневни живот.

Артур Самјуел дефинисао је машинско учење као „*Област проучавања, која даје рачунарима способност да уче без да су експлицитно програмирани*”. Постао је познат 1950-их година када је написао програм за играње даме. У то време је био један од најкомплицованијих програма за играње даме и познат је као један од првих адаптивних програма. Програмирао је рачунар да игра велики број партија против самог себе, чиме је постигао да програм схвати које позиције на табли обично воде до победе, а које до пораза и тиме постигне добре и избегне лоше позиције [4].

Дефиниција Артура Самјуела је класична дефиниција машинског учења. Другу значајну дефиницију дао је Том Мичел [6]: „*Каже се да рачунарски програм учи из искуства E у вези са неком класом задатака T и мером перформанси P , ако се његова перформанса у задацима из класе T , мерена помоћу P , побољшава са искуством E* ”. Наглашава кључне елементе који одређују да ли рачунарски програм заиста учи. Према овој дефиницији, програм се сматра да учи уколико се његова способност обављања задатака побољшава кроз искуство.

4.1 Подела машинског учења

Машинско учење дели се на четири категорије:

- 1) **Надгледано учење** (енгл. Supervised learning) – Креирање модела на основу обележених података, где су улазни подаци повезани са одговарајућим излазима [8]. Систем је формиран тако да предвиђа исходе на основу тренирања на задатом скупу података. Овај приступ подсећа на процес људског учења уз помоћ инструктора, користећи конкретне примере како би извео опште закључке.
- 2) **Ненадгледано учење** (енгл. Unsupervised learning) – подразумева обучавање на скупу података који не садржи обележене податке [8]. Овакав приступ користан је за проналажење структура, образаца, група, кластера и слично у подацима.
- 3) **Полунадгледано учење** (енгл. Semi – Supervised Learning) – Представља комбинацију надгледаног и ненадгледаног учења [8]. Дефинише се излаз за мали део података, затим се врши „псеудо-лабелирање” над преосталим подацима (додавање привремених или „псеудо” ознака на основу предикција модела тренираног над обележеним подацима). Псеудо - ознаке се затим користе као

обележени подаци у даљем процесу учења, чиме се долази до ефикасније искоришћености доступне количине података.

- 4) **Учење са подстицајем** (енгл. Reinforcement Learning) – Специфичан облик машинског учења који омогућава софтверским агентима да дефинишу оптималне стратегије понашања с циљем постизања жељених резултата [8]. Заснива се на принципу покушаја и грешке, где се награђују позитивни исходи а кажњавају негативни. Како агент скупља искуство кроз интеракцију са динамичним окружењем, постаје све бољи у доношењу одлука које воде ка остварењу задатих циљева, без директног надзора. Практичан пример примене учења са подстицајем је у аутономној вожњи.

4.2 Апликације

Машинско учење може да се појави у многим апликацијама, са различитим типовима података. Кључна вештина лежи у способности да се широк спектар различитих проблема поједностави и сведе на неколико једноставних и јасних модела.

Рангирање веб страница је процес у ком претраживач, након примљеног упита, проналази и приказује најрелевантније веб странице [7]. На пример, уколико се претражује појам „ Лондон ”, претраживач враћа сортирану листу страница на основу унетог упита. На основу садржаја веб странице, њене структуре, учесталости са којом корисници прате линкове након претраге, претраживач одређује које од њих су релевантне. **Колаборативна** филтрација је слична метода која се користи у системима препоруке, као што су платформе попут Amazona, Netflixа, Spotify-а,... Анализира оцене, обрасце понашања и изборе великог броја корисника и на основу тога препоручује садржај. Проблем је сличан рангирању, међутим овде не постоји експлицитан упит, већ се листа сортира искључиво на основу претходних одлука.

Класификациони проблеми су фундаментални за многе апликације у машинском учењу и често представљају полазну тачку у изградњи интелигентних система, који могу доносити одлуке на основу података [7]. На пример препознавање лица представља део многих сигурносних апликација. Потребно их је класификовати у неку од категорија (имена лица у бази) или препознати да се ради о непознатом лицу, на основу слике или видео снимка те особе. Сличан проблем је и верификација, код које је потребно потврдити идентитет особе. За разлику од препознавања лица, верификација класификује особе у две категорије да/не.

Предикција можданог удара представља **бинарни класификациони проблем**, чији је циљ да расподели податке у једну од две могуће класе. Ове две класе означене су као позитивна (1) и негативна (0) класа. На основу одређених карактеристика особа у скупу података модел предвиђа да ли је излаз који је обележен као мождани удар тј. „stroke” 1 или 0.


5. КЛАСИФИКАЦИОНИ МОДЕЛИ У НАДГЛЕДАНОМ УЧЕЊУ

5.1 Логистичка регресија

Логистичка регресија (енгл. *Logistic Regression*) представља класификациони алгоритам надгледаног учења, који се најчешће користи за бинарну класификацију [5]. Може да се тумачи и као проширена верзија линеарне регресије, где се излазни резултати трансформишу у бинарни формат, чиме омогућавају класификацију података.

Постоје одређени предуслови који морају бити испуњени како би логистичка регресија постигла добре резултате. Прво, скуп података мора да буде довољно обиман и без аномалија, како би омогућио моделу препознавање образаца и правилну класификацију. Ради постизања ефикасности логистичке регресије, важно је да не постоје значајне корелације међу независним променљивим, тј. не постоји превелика сличност у вредностима различитих променљивих.

Приликом моделовања логистичке регресије потребно је користити активациону функцију (Слика 2), чија главна намена је мапирање улазних вредности у излазну вредност у опсегу $[0,1]$. Улазна вредност представља излаз линеарне регресије, док излазне вредности логистичке регресије представљају вероватноћу припадања некој класи на основу тих вредности.



Слика 2. Активационе функције [35]

Активациона функција која се најчешће користи у моделу логистичке регресије је функција под називом сигмоид.

Нека је дат скуп независних променљивих X и очекиваних излаза Y :

$$X = \begin{bmatrix} x_{11} & \cdots & x_{1m} \\ \vdots & \ddots & \vdots \\ x_{n1} & \cdots & x_{nm} \end{bmatrix} \quad Y = \begin{cases} 0, & \text{if Class 1} \\ 1, & \text{if Class 2} \end{cases}$$

Први корак у примени логистичке регресије је примена линеарне комбинације независних променљивих:

$$z = \left(\sum_{i=1}^n \omega_i x_i \right) + b$$

Где је ω_i тежина за сваки атрибут тј. његов значај у датом скупу, а b константа која служи за постизање боље флексибилности модела померањем линеарне функције за ту вредност. Коначно користи се једначина сигмоидне функције за одређивање вероватноћа:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$


Вероватноћа припадности одређеној класи математички се може представити као:

$$\begin{aligned} P(y = 1) &= \sigma(z) \\ P(y = 0) &= 1 - \sigma(z) \end{aligned}$$

Предности логистичке регресије су једноставност интерпретације, пружање јасне информације о значају сваког атрибута као и брзина извршавања. Међутим, може да буде и превише једноставна за поједине моделе, што доводи до потенцијалне појаве претренираности модела. Због тога, као и због потребе за линеарном повезаношћу међу променљивим, ретко се користи у решавању сложених проблема.

5.2 К најближих суседа

К најближих суседа (енгл. *K nearest neighbors* – *KNN*) представља једноставан и широко коришћен алгоритам у машинском учењу, који је применљив како за класификацију тако и за регресију [21]. Једна од главних предности *KNN* алгоритма је то што је непараметарски, односно не захтева претходне претпоставке о расподели података. Ова особина му омогућава да буде прилагодљив и применљив на широк спектар проблема у различитим областима.



Слика 3. *KNN* алгоритам [22]

Приложена слика (Слика 3) илуструје принцип функционисања *KNN* алгоритма, који примењује дефинисане кораке за класификацију података, тако што се ослања на мере удаљености између тачака у тест сету и постојећих узорака у тренинг сету.

Преглед података

Први корак у примени *KNN* алгоритма је идентификација тачке која се класификује и обухвата анализу расположивих података. Идентификована тачка у примеру је сиве боје, док у тренинг сету постоје три различите класе: зелена, жута и наранџаста.

Израчунавање удаљености

Следећи корак представља израчунавање удаљености циљне тачке од осталих тачака у скупу података. Удаљеност може да се мери на основу различитих метрика, као што су:


- Еуклидова удаљеност – најкраће растојање између две тачке у простору тј. дужина праве линије која спаја те две тачке

- Менхетн растојање – метрика која мери укупну удаљеност између две тачке у мрежи, када је кретање омогућено само у правцима дуж оса тј. представља збир апсолутних вредности разлика координата тачака

Одабир најближих суседа

Након израчунавања удаљености бира се K најближих суседа. Избор одговарајуће вредности за K је од пресудног значаја за перформансе модела. Мања вредност K обично води ка мањој грешци али уз већу варијансу, што може да доведе до *overfitting-a*, док већа вредност за K доводи до смањене варијансе и повећане грешке, што обично доводи до појаве под називом *underfitting*. Тежи се моделу који има малу грешку и малу варијансу, али је то тешко постићи (Слика 4а). За одабир K најчешће се користи „Метода лакта“ (Слика 4б). Графички приказ те методе показује просечну грешку или дисперзију на у-оси, и вредности K на х-оси. Са повећањем вредности K , дисперзија у почетку значајно опада, али након одређеног тренутка темпо смањења постаје спорији. Тачка прелома криве која формира облик налик лакту представља оптималну вредност за K .

Препоручљиво је користити непарну вредност за K како би се избегле нерешене ситуације током бинарне класификације, док је такође пожељно бирати што већу вредност за K уколико дати скуп има велики број аномалија. Ови суседи бирају се на основу најкраће удаљености од циљне тачке.




Слика 4. Однос пристрасности и варијансе у KNN алгоритму (а) [36], метода лакта за избор оптималног K (б) [37]

Одлука о класи

Финални корак је одабир класе на основу K најближих суседа. Сваки сусед даје глас за класу којој припада, а класа са највећим бројем гласова постаје коначна класификација циљне тачке. У примеру највећи број гласова припада жутој класи, тако да ће сива тачка бити класификована у жуту класу.

5.3 Стабло одлуке

Стабло одлуке (енгл. *Decision Tree – DT*) је алгоритам надгледаног учења који се користи за класификацију. Њихова јасна структура и визуелизација чине их веома корисним, јер омогућавају лако разумевање логике која стоји иза одлука модела [24].



Слика 5. Стабло одлуке [23]


Стабло одлуке (Слика 5) функционише као хијерархијска структура која доноси одлуке на основу атрибута података. Процес почиње од коренског чвора (енгл. *Root Node*) који представља цео скуп података и дели се на више хомогених скупова, што се назива раздвајање (енгл. *Splitting*). Чвор подељен на више под-чворова, представља чвор одлуке (енгл. *Decision Node*), док се чворови који нису даље подељени називају листови или терминални чворови (енгл. *Terminal Node*). Свака грана или под-стабло (енгл. *Branch/Sub-Tree*) представља део целокупне структуре стабла и може се сматрати мањом јединицом стабла. Родитељски чвор (енгл. *Parent Node*) је онај који се дели на више под-чворова, који представљају децу (енгл. *Child Node*).

Примери су класификовани тако што се воде кроз стабло, од коренског до терминалног чвора, где се доноси коначна одлука о класификацији. Сваки чвор у стаблу представља тест или питање, а свако раздвајање тог чвора на гране одговара различитим исходима тог теста. Овај процес се понавља рекурзивно, кроз под-стабла, док се не стигне до терминалног чвора или листа који нам пружа финалну класификацију.

Једна од предности стабла одлуке је то што може да обрађује нелинеарне податке, што га чини погодним за сложене проблеме где однос међу променљивим није линеаран. Такође не захтева нормализацију или стандардизацију, па предобрада података постаје једноставнија. С друге стране, има и одређене недостатке. Често је сложеније и спорије у примени у односу на друге алгоритме, што може да представља изазов када се ради са великим скуповима података. Поред тога осетљиво је на мале промене у подацима, што може довести до значајне промене у структури стабла и резултатима класификације.

5.4 Насумична шума

Насумична шума (енгл. *Random Forest*) представља моћну технику учења засновану на стаблима одлуке. Њен принцип рада заснива се на обуци великог броја стабала, при чему се за свако стабло користи насумичан подскуп података, као и насумично одабране карактеристике у свакој фази изградње [25]. Овај приступ заснован је на концепту ансамбл учења, који омогућава да више модела раде заједно, доносећи прецизније и поузданије одлуке него што би то могао било који појединачни модел. Увођењем разноврсности међу стаблима значајно се смањује ризик од претренираности модела.



Слика 6. Насумична шума [38]


Један од кључних принципа *RF* алгоритма је техника под називом *bagging* (*bootstrap aggregating*) [27]. Приликом примене ове технике узорковањем са заменом се стварају различити подскупови података, при чему се сваки подскуп користи за обуку појединачних стабала. Овим процесом се уноси значајна варијација у процес обуке, што омогућава боље моделовање комплексних односа у подацима. Свако стабло се на тај начин фокусирано на специфичне аспекте података, доприносећи већој прецизности и поузданости коначних одлука.

Коначна одлука у *RF* алгоритму (Слика 6) у задацима класификације доноси се на основу механизма гласања [26]. Свако појединачно стабло доноси своју предикцију класе, а класа која добије највећи број гласова је изабрана као коначна предикција. На пример ако у *RF* моделу постоји 50 стабала, где класи А припада 20 предикција, а класи Б 30, коначна предикција биће класа Б која је добила већински број гласова.

RF алгоритам поседује значајне предности које га чине веома ефикасним у машинском учењу. Веома је користан приликом обраде великих скупова података, јер дели податке на више делова и обрађује их паралелно, чиме постиже већу брзину и ефикасност. Осим тога алгоритам пружа могућност процене значаја појединих карактеристика, што омогућава идентификацију елемената који су кључни за предвиђање.

5.5 Метода потпорних вектора


Метода потпорних вектора (енгл. *Support Vector Machine – SVM*) представља алгоритам машинског учења који може да се примењује како у класификацији, тако и у регресији. Подаци се третирају као вектори у n -димензионалном простору, док је главни циљ успостављање $(n-1)$ -димензионалне хиперравни, која ефикасно раздваја групе података. Изабрана хиперраван треба да максимизира удаљеност до најближих тачака сваке класе са обе стране, које се називају потпорни вектори, чиме се омогућава оптимално раздвајање података у различите категорије. Ова удаљеност назива се маргина и представља растојање које може да пређе хиперраван пре него што досегне неку тачку. Већа маргина омогућава стабилно и поуздано раздвајање података и самим тим прецизну класификацију.



Слика 7. SVM линеарни и нелинеарни проблеми [28]

Метода потпорних вектора има две различите врсте проблема, линеарне и нелинеарне. Линеарни проблеми су они код којих постоји бар једна права која јасно раздваја класе података, док код нелинеарних проблема не постоји таква права (Слика 7). Уколико имамо дводимензионални простор приликом примене линеарног раздвајања хиперраван је линија, док је код вишедимензионалног простора раван. На Слици 8а приказано је линеарно раздвајање података, где раван $H1$ не успева да изврши класификацију података, међутим иако равни $H2$ и $H3$ обе врше класификацију, $H3$ хиперраван је оптимални класификатор јер има најширу маргину. Линеарни класификатори употребљиви су и на нелинеарним подацима употребом Кернел методе (Слика 8б). Њено функционисање своди се на премештање података, уз помоћ кернел функције у простор који садржи више димензија, без рачунања координата у тим димензијама. Најпознатије кернел методе су:

1. Гаусова – Генерише нове карактеристике на основу удаљености сваке тачке у простору у односу на одређену тачку
2. Полиномијална - Процес који генерише нове карактеристике кроз полиномску комбинацију постојећих



Слика 8. SVM линеарно раздвајање класа (а) [28], нелинеарно раздвајање класа применом кренел функције (б) [28]

SVM је алгоритам машинског учења који има бројне предности. Погодан је за рад са подацима у више димензија, захваљујући способности обрађивања великог броја карактеристика. Поред тога постиже високу тачност и приликом тренирања модела са ограниченим бројем узорака, и с обзиром на чињеницу да има уграђен механизам који смањује ризик од претренираности, вероватноћа појаве *overfitting*-а је веома мала. Поред бројних предности, алгоритам садржи и одређене мане. *SVM* поседује слабу ефикасност при раду са великим скуповима података, што доводи до проблема са перформансама као и до дугог обучавања модела приликом рада са великим бројем карактеристика у таквим скуповима.

6. ОПИС СКУПА ПОДАТАКА

Скуп података [10] који је коришћен за предикцију možданог удара садржи различите демографске, медицинске и животне факторе, за које ће се у даљем истраживању испитивати у којој мери утичу на здравствено стање пацијента. Циљ је утврдити колико ови фактори доприносе ризику од možданог удара и на који начин се могу употребити за прецизну предикцију možданог удара. Скуп података преузет је са *Kaggle* платформе и садржи 5110 појединаца. У Табели 1. приказани су атрибути из датог скупа, заједно са својим типовима, вредностима и описима.

ТАБЕЛА 1. Скуп података

Атрибут	Тип/Вредност	Опис
<i>id</i>	<i>Integer</i>	Јединствени идентификатор пацијента који осигурава непоновљивост уноса у базу
<i>gender</i>	<i>Object (Male, Female, Other)</i>	Информација о полу пацијента
<i>age</i>	<i>Floating point number</i>	Године живота пацијента
<i>hypertension</i>	<i>Integer (0, 1)</i>	Идентификатор присуства хипертензије, 0 означава одсуство тог стања, а 1 означава његово присуство
<i>heart_disease</i>	<i>Integer (0, 1)</i>	Означава да ли пацијент има срчану болест, 0 указује на одсуство, а 1 на присуство болести
<i>ever_married</i>	<i>Object (Yes, No)</i>	Подаци о брачном статусу пацијента, који могу бити релевантни за анализу животног стила и његовог утицаја на здравље пацијента
<i>work_type</i>	<i>Object (children, Govt_job, Never_worked, Private, Self-employed)</i>	Тип запослења пацијента, који може указати на различите нивое изложености стресу и физичким активностима
<i>Residence_type</i>	<i>Object (Rural, Urban)</i>	Тип пребивалишта пацијента, што може указати на различите животне услове и приступ здравственој нези
<i>avg_glucose_level</i>	<i>Floating point number</i>	Просечан ниво глукозе у крви пацијента, који служи као индикатор метаболичког здравља и ризика од хроничних болести
<i>bmi</i>	<i>Floating point number</i>	Индекс телесне масе, показатељ телесне кондиције и гојазности, може бити фактор ризика за кардиоваскуларне болести
<i>smoking_status</i>	<i>Object (formerly smoked, never smoked, smokes, Unknown)</i>	Статус пушења пацијента, указује на навике пушења и потенцијални утицај на здравље
<i>stroke</i>	<i>Integer (0, 1)</i>	Индикатор да ли је пацијент доживео možдани удар, где 0 указује да није, а 1 указује на то да јесте

7. ПРОЦЕС ОБРАДЕ ПОДАТАКА И ИЗГРАДЊЕ МОДЕЛА

Процес обраде података и изградње класификационог модела за предикцију можданог удара представљен је на дијаграму (Слика 9), почевши од предобраде података, која обухвата идентификацију и обраду недостајућих вредности, откривање аномалија, визуелизацију података ради бољег разумевања њихове структуре и понашања, конверзију категоријских података у нумеричке вредности и балансирање података. Након ове фазе, подаци се деле на тренинг и тест сетове, чиме се обезбеђује ефикасна обука модела и процена њихових перформанси на непознатим подацима. У наредној фази врши се стандардизација података, како би се атрибути довели на исту скалу, што је од кључне важности за моделе који су осетљиви на распон вредности. Завршна фаза обухвата изградњу и тестирање претходно описаних класификационих модела, након чега се анализирају добијени резултати, како би се идентификовали модели са најбољим перформансама у предикцији појаве можданог удара.




Слика 9. Дијаграм процеса обраде података и изградње модела за предикцију можданог удара

8. ПРЕДОБРАДА ПОДАТАКА

Предобрада података (енгл. *Data preprocessing*) представља суштински корак у процесу припреме података за анализу, с циљем побољшања њиховог квалитета и конзистентности [20]. Овај процес обезбеђује да подаци буду структурирани и прилагођени за примену различитих модела машинског учења. Темељно спроведена предобрада осигурава већу тачност и поузданост модела који се примењују на датом скупу података, чиме се значајно побољшавају целокупни резултати и закључци који произилазе из њих.

8.1 Идентификација и обрада недостајућих вредности

Појам недостајуће вредности односи се на вредности који изостају за одређени атрибут у датом скупу података. Могу се појавити у различитим облицима, као што су нулте вредности, празне ћелије или посебни симболи попут „NA”. Недостајуће вредности могу представљати озбиљан изазов у процесу анализе података, јер значајно могу да утичу на квалитет и поузданост резултата. Смањење величине узорака које проистиче из недостајућих вредности може довести до мање прецизне и мање поуздане анализе, док неправилно управљање овим подацима може унети пристрасност, што резултира изобличеним закључцима.



Слика 10а. Приказ недостајућих вредности у датом скупу и Слика 10б. Хистограм за BMI

У датом скупу података идентификоване су недостајуће вредности за променљиву *BMI*, са укупно 201 недостајућом вредношћу (Слика 10а), па је неопходно предузети одговарајуће кораке за њихову обраду. Потенцијални приступи укључују њихово уклањање или попуњавање коришћењем метода као што су медијана или средња вредност.

На основу хистограма који приказује расподелу вредности *BMI* (Слика 10б), може се закључити да расподела приказује десну асиметрију, што значи да је већи део података груписан око нижих вредности, док се мањи број виших вредности јавља у десном делу расподеле. Највећа концентрација података је у опсегу од 20 до 40, док су вредности ван овог интервала ређе. С обзиром на асиметрију расподеле, коришћење медијане представља бољу опцију за попуњавање недостајућих вредности. Медијана је погоднија у случају десно асиметричних података, јер није осетљива на више вредности као што је средња вредност. Попуњавање недостајућих података медијаном омогућава да резултати буду репрезентативнији.

8.2 Детекција аномалија

Аномалија представља одступање од уобичајених образаца понашања, у датом скупу података. Детекција аномалија или детекција одступања базира се на процесу проналажења образаца у подацима који се знатно разликују од њиховог стандардног или очекиваног понашања [30]. Уобичајени приступ у детекцији аномалија је дефинисање границе која окружује стандардне податке. На тај начин врши се њихова сегментација у односу на одступајуће вредности.

Аномалије значајно утичу на функционисање већине алгоритама машинског учења, стога је у великом броју случајева пожељно њихово уклањање. Постоји одређени број апликација, где одступајуће вредности могу бити од великог значаја за решавање проблема. На пример у детекцији превара, аномалије могу бити корисне јер показују неуобичајене обрасце понашања, као што су трансакције које се значајно разликују од нормалних.

За детекцију аномалија користе се различити алгоритми,. У овом истраживању примењен је алгоритам познат као интерквartilни опсег (енгл. *Interquartile Range – IQR*). *IQR* представља статистичку меру која показује распон унутар којег се налази средњих 50% података [29]. Први корак је сортирање података у растућем редоследу, где се затим подаци деле на 4 једнака дела, подељена кvартилима. Први кvартил *Q1* означава 25. перцентил скупа података, други кvартил *Q2* представља 50. перцентил, који уједно одговара медијани, док трећи кvартил *Q3* означава 75. перцентил података. *IQR* се рачуна као разлика трећег и првог кvартила, чиме се добија опсег у ком лежи средњих 50% података:

$$IQR = Q3 - Q1$$


Аномалије се детектују дефинисањем две границе, горње и доње:

Горња граница: $Q3 + 1,5 * IQR$

Доња граница: $Q1 - 1,5 * IQR$


Подаци који премашују горњу или падају испод доње границе сматрају се аномалијама.

На основу анализе скупа података за предикцију možданог удара, примећују се различити резултати у односу на аномалије по променљивим. За променљиву *age* (старост), графички приказ не показује присуство аномалија (Слика 11), што указује да су све вредности у оквиру очекиваних граница. Тренд линија на овом графику одражава стабилан просек података, без значајних одступања.



Слика 11. Графички приказ аномалија за променљиву *age*

Међутим, за променљиве *avg_glucose_level* (просечан ниво глукозе) (Слика 12а) и *bmi* (индекс телесне масе) (Слика 12б), уочено је присуство великог броја аномалија. На графику за *avg_glucose_level* детектовано је 627 аномалија, док је за *bmi* идентификовано 126 аномалија. Тренд линије на овим графицима указују на просечне вредности, али су аномалије, које су приказане црвеним X тачкама, знатно изнад или испод ових вредности.




Слика 12. Графички приказ аномалија за променљиву *avg_glucose_level* (а) и *bmi* (б)

У даљој анализи података, аномалије које су идентификоване за променљиве *avg_glucose_level* и *bmi* уклоњене су применом методе замене са средњом вредношћу. Овај приступ омогућава да се екстремне вредности које значајно одступају од нормалних распона замене просечним вредностима тих променљивих, чиме се смањује утицај аномалија на коначне резултате анализе.

8.3 Визуелизација података

Графичко приказивање података назива се визуелизација, и омогућава лакше и брже разумевање сложених скупова података. Путем различитих типова графика, као што су дијаграми расподеле (енгл. *Pie chart*), корелационе матрице, стубичасти дијаграми (енгл. *Bar chart*), и *violin* плотови, могуће је приказати однос између различитих варијабли или група варијабли у процени ризика од можданог удара, као што су пол, брачни статус, хипертензија итд.

Први графикон (Слика 13) представља један пример деловања категоричких вредности на мождани удар тј. расподелу можданог удара по полу. Подаци су приказани у облику *Pie chart*-а и јасно се види да већину популације чине жене које нису претрпеле мождани удар (55.8%), док је удео жена са можданим ударом значајно мањи (2.8%). У истом контексту, мушкарци који нису претрпели мождани удар чине 39.3%, док само 2.1% мушкараца има историју можданог удара. Жене имају за нијансу већу склоност ка можданом удару на основу овог графикона.




Слика 13. Расподела можданог удара по полу

На приказаном графику (Слика 14) налазе се виолин плотови који приказују дистрибуцију три нумеричке карактеристике у односу на присуство или одсуство можданог удара. Дистрибуција података је представљена за три променљиве: *age*, *bmi* и *avg_glucose_level*. Виолин плотови омогућавају визуализацију облика дистрибуције података, уз интегрисане информације о распону и густини података.

Age Distribution by Stroke: Лева страна графикана приказује дистрибуцију старости за особе које нису доживеле мождани удар, док десна страна показује дистрибуцију за оне који су доживели мождани удар. Видљиво је да су особе које су доживеле мождани удар углавном старије, са већом густином око 60-80 година. Насупрот томе, особе које нису имале мождани удар распоређене су на ширем опсегу година, са врхом густине око 40 година, што сугерише да је старост значајан фактор ризика за мождани удар.


BMI Distribution by Stroke: У оба случаја (и за особе са и без можданог удара), индекс телесне масе има сличан распон, али је концентрација код оних који су имали мождани удар благо повећана око вредности 30, што сугерише да је повећан *bmi* могућ, али не и пресудан фактор за мождани удар. Закључак је да је *bmi* код људи који су имали мождани удар у просеку нешто виши, али ова разлика није довољно велика да би се могла сматрати главним узрочником.

Avg_glucose_level Distribution by Stroke: Овај график јасно показује да особе које су имале мождани удар имају виши ниво глукозе у крви у поређењу са онима који нису доживели мождани удар. За оне без можданог удара, већина вредности се креће у распону од 60 до 120, док се код оних са можданим ударом концентрација повећава на 100–130, са репом који протеже ка још вишим вредностима. Овај резултат указује да је виши ниво глукозе у крви повезан са већим ризиком од можданог удара.



Слика 14. Утицај нумеричких карактеристика на мождани удар

Корелациона матрица (Слика 15) је табеларни приказ који показује степен корелације, који варира у опсегу од -1 до 1, између различитих променљивих у датом скупу података. Најјача корелација са можданим ударом је примећена код старости (0.25), што значи да старије особе имају већу вероватноћу да доживе мождани удар. Хипертензија (0.13) и срчана обољења (0.13) такође показују значајан утицај, што указује на то да људи са високим крвним притиском и срчаним проблемима имају повећан ризик од можданог удара. С друге стране, индекс телесне масе (BMI) има слабу корелацију (0.05) са можданим ударом, што показује да они играју мању улогу у односу на друге факторе.




Слика 15. Корелациона матрица

8.4 Конверзија категоричких података у нумеричке вредности

Конверзија података или енкодирање података представља кључни корак у предобрици у машинском учењу, где се категоричке вредности претварају у нумерички формат, како би алгоритми могли ефикасно да их обрађују и препознају обрасце у подацима, с обзиром да већина њих захтева нумеричке улазе за рад. Постоје различите технике конверзије, а у овом истраживању примењена је техника под називом *Label Encoding*, која свакој категорији унутар колоне додељује јединствену нумеричку вредност [31]. На пример, ако постоји колона *Places*, са вредностима *New York*, *LA*, *Chicago*. *Label Encoding* их претвара у нумеричке вредности 0, 1, 2, при чему 0 представља *New York*, 1 *LA* и 2 *Chicago*.

8.5 Балансирање података

Неуравнотежени подаци представљају скупове података у којима једна класа бројчано знатно надмашује другу, што може довести до пристрасности према већинској класи. Због постојања неуравнотежености, може доћи до игнорисања мањинске класе и њеног третирања као шум, што доводи до неисправних резултата. Постоје различите методе које се користе за балансирање података попут *oversampling*-а и *undersampling*-а. У овом истраживању, с обзиром да постоји изражена небалансираност у категорији *stroke* (Слика 16), употребљена је метода *SMOTE* (енгл. *Synthetic Minority Oversampling Technique*) [32]. *SMOTE* је често коришћена техника, која балансирање врши тако што синтетише нове примере мањинске класе на основу постојећих података насумичним одабиром к најближих суседа за сваки пример, без губитака података из већинске класе.



Слика 15. Приказ неуравнотежености класе *stroke*

9. ПОДЕЛА ПОДАТАКА НА ТРЕНИНГ И ТЕСТ СЕТ

Подела података на тренинг и тест сет је кључни корак у машинском учењу који омогућава процену перформанси модела. Тренинг сет се користи за обуку модела, односно за учење образаца у подацима, док се тест сет користи за проверу тачности модела на подацима које није видео током обуке. Ова подела је важна јер спречава прекомерно прилагођавање модела на тренинг податке и осигурава да модел може да се генерално примени на нове, непознате податке. Типична подела је 70-80% података за тренинг сет и 20-30% за тест сет, али овај однос може варирати у зависности од величине и природе скупа података.

10. СТАНДАРДИЗАЦИЈА ПОДАТАКА

Feature scaling представља важан корак у машинском учењу, јер омогућава тренирање ефикасних и прецизних модела. Технике као што су стандардизација и нормализација користе се за скалирање података, чиме се омогућава постизање сличног распона међу променљивим и спречава нарушавање резултата доминацијом већих вредности. Главна разлика између стандардизације и нормализације је у начину скалирања података. Нормализација скалира податке употребом минималне и максималне вредности у распону $[0,1]$ или $[-1,1]$, међутим осетљива је на одступања. Стандардизација скалира податке употребом стандардне девијације и средње вредности, што резултира подацима са просечном вредношћу 0 и стандардном девијацијом 1. За разлику од нормализације није осетљива на аномалије или одступања.

Стандардизација је погодна за алгоритме машинског учења попут логистичке регресије, к најближих суседа и методе потпорних квадрата, стога је и употребљена у овом раду. За скалирање употребљена је техника предобраде *StandardScaler* из библиотеке *scikit-learn*, која функционише тако што уклања средњу вредност и скалира до јединичне варијансе. За сваки атрибут прво се рачуна његова средња вредност, затим се од сваке појединачне вредности тог атрибута одузима та средња вредност, чиме се подаци центрирају око нуле. Потом се дељењем са стандардном девијацијом ти подаци скалирају, што обезбеђује да варијанса података буде једнака 1.

11. ИЗГРАДЊА МОДЕЛА И АНАЛИЗА РЕЗУЛТАТА

11.1 Изградња модела

Приликом процеса изградње модела, велики значај представља подешавање хиперпараметара. Хиперпараметри су параметри које модел не учи у току процеса тренирања, већ су унапред подешени како би се модел оптимизовао. За сваки модел коришћен у овом истраживању примењено је подешавање хиперпараметара.

Логистичка регресија: Код логистичке регресије, кључни хиперпараметри укључују *penalty*, који одређује врсту регуларизације тј. технике која се користи да би се спречило преобучавање модела, и параметар *C*, који контролише снагу те регуларизације. Вредност *solver* одређује алгоритам који ће се користити за решавање оптимизационог проблема.

К најближих суседа: Основни хиперпараметри за *KNN* модел укључују број суседа *n_neighbors*, начин мерења удаљености *weights* и величину листа *leaf_size*. Ови параметри

одређују како модел разматра најближе тачке у подацима и омогућавају прилагођавање модела у зависности од различитих типова података.

Стабло одлуке: За стабло одлуке, хиперпараметри су *criterion*, који дефинише метрику за мерење квалитета подела, *max_depth*, који одређује дубину стабла, и *min_samples_split*, који уводи минималан број примерака потребних за поделу чвора.

Насумична шума: Код насумичне шуме, важни хиперпараметри укључују број стабала *n_estimators*, максималну дубину *max_depth*, и минимални број примерака за поделу чвора *min_samples_split* и листове *min_samples_leaf*.

Метода потпорних вектора: Кључни хиперпараметри за *SVM* укључују *C*, који контролише снагу регуларизације, *kernel*, који дефинише функцију за мапирање података у виши димензионални простор, и *gamma*, који контролише утицај појединачних тачака података.

Како би се добило што прецизније подешавање хиперпараметара, употребљена је техника унакрсне валидације (енгл. *Cross – validation*), којом се детектује да ли постоји претренираност. Идеја унакрсне валидације тј. унакрсне валидације са к партиција, је да се скуп података подели на к делова или итерација, где у сваком делу постоји валидациони и тренинг сет. У свакој итерацији модел се тренира на тренинг сету, и тестира на валидационом сету. Након к итерација, рачуна се средња вредност на основу добијених резултата у свакој итерацији, и тај број представља меру перформансе модела.



Слика 16. Унакрсна валидација са к партиција [15]

У овом истраживању, техника *Grid Search* примењена је у комбинацији са унакрсном валидацијом ради оптималног подешавања хиперпараметара. *Grid Search* анализира различите комбинације хиперпараметара, док унакрсна валидација осигурава да свака од тих комбинација буде тестирана на више подскупова података. Овај процес резултира избором најбољих вредности хиперпараметара, чиме се постиже оптимална тачност и генерализација модела.

11.2 Анализа резултата

Сумирање свих перформанси модела машинског учења може да се врши на основу конфузионе матрице (Табела 2). Посебно је корисна код класификационих модела, јер визуелно може да прикаже број тачних и нетачних предвиђања у односу на стварне вредности.

Конфузиона матрица састоји се од:

1. **Стварних позитивних** (енгл. *True Positive - TP*) – Исправно предвиђање позитивне класе, стварни исход је позитиван
2. **Стварних негативних** (енгл. *True Negative - TN*) – Исправно предвиђање негативне класе, стварни исход негативан
3. **Лажних позитивних** (енгл. *False Positive - FP*) – Погрешно предвиђање позитивне класе, стварни исход негативан
4. **Лажних негативних** (енгл. *False Negative - FN*) – Погрешно предвиђање негативне класе, стварни исход позитиван, посебно лоше у медицинским истраживањима. На пример, ако модел предвиди да пацијент није у ризику од можданог удара, а он заправо јесте, то може довести до пропуштања критичне интервенције и значајно угрожавања здравља пацијента.

ТАБЕЛА 2. Конфузиона матрица

Предвиђена класа / стварна класа	Позитивно	Негативно
Позитивно	Стварно позитивно (TP)	Лажно позитивно (FP)
Негативно	Лажно негативно (FN)	Стварно негативно (TN)

Кључне метрике за процену перформанси модела заснивају се на матрици конфузије:

- 1) **Тачност** (енгл. *Accuracy*) – представља укупну успешност модела израчунавањем односа тачно предвиђених позитивних и негативних, у односу на укупан број предвиђања [33].

$$\text{Тачност} = \frac{TP + TN}{TP + TN + FP + FN}$$

Уколико подаци нису балансирани, тачност тада није погодна мера за процену квалитета модела. На пример уколико једној класи припада 95% података, а другој 5%, тачност која

је постигнута може да износи 0.95, међутим то није урачунљиво јер је извршена једноставна класификација примера из већинске класе.

- 2) **Прецизност** (енгл. *Precision*) – Однос тачно предвиђених позитивних случајева и свих позитивно предвиђених [33].

$$\text{Прецизност} = \frac{TP}{TP + FP}$$

Висока прецизност значи да ако модел заиста предвиди позитиван резултат, шансе да је то тачно су велике.

- 3) **Одзив** (енгл. *Recall*) – Однос стварно позитивних случајева и збира стварно позитивних и лажно негативних. Погодан за откривање свих стварних позитивних [33].

$$\text{Одзив} = \frac{TP}{TP + FN}$$

Приликом процене ризика од можданог удара израчунавање одзива је од великог значаја. Уколико се не пронађу сви стварно позитивни случајеви, односно сви пацијенти који су склони појави можданог удара, крајњи исход може да има кобне последице по поједине пацијенте.

- 4) **F1-мера** (енгл. *F1 - score*) – Представља комбинацију прецизности и одзива [33].

$$F1 = \frac{2 * \text{Прецизност} * \text{Одзив}}{\text{Прецизност} + \text{Одзив}}$$

На приложеној слици (Слика 17) приказани су резултати модела пре и после подешавања хиперпараметара. За предвиђање можданог удара, *Random Forest* представља најбољи модел, због одличног баланса између прецизности (0.94), одзива (0.96) и F1-мере (0.95). Овај модел осигурава да ће већина позитивних случајева бити правилно идентификована, уз прављење минималног броја лажно позитивних предвиђања, што је од великог значаја у медицинским истраживањима.

Други најбољи алгоритам је *SVM*, који након подешавања хиперпараметара показује висок одзив (0.95) и доста побољшану F1-меру (0.90). Овај модел је добар уколико је приоритет идентификација што већег броја случајева можданог удара, међутим може да произведе нешто већи број лажно позитивних резултата у односу на *Random Forest*.

KNN такође показује веома велики одзив (0.98), што га чини поузданим за препознавање потенцијалних случајева можданог удара. Његова прецизност од 0.85

указује на доста већи број лажно позитивних случајева, што је генерално лошије од алгоритама *Random Forest* и *SVM*.

Decision Tree модел је стабилан са прецизношћу од 0.91 и одзивом 0.92, међутим заостаје у односу на остале алгоритме у погледу одзива што може да значи да ће пропустити већи број стварно позитивних случајева.

Logistic Regression је модел који показује најслабије перформансе, са прецизношћу од 0.79, одзивом од 0.84 и F1-мером 0.81. Овај модел, због своје једноставности, може бити користан у великом броју случајева, међутим то овде није случај јер може генерисати велики број лажно позитивних случајева и пропустити велики број стварно позитивних.

На основу анализе *Random Forest* представља најпоузданији модел, на основу баланса између прецизности и одзива тј. на основу F1-мере, што га чини идеалним за врсту оваквог медицинског истраживања.



Слика 17. Поређење префморманси различитих модела машинског учења у процени ризика од можданог удара

12. ЗАКЉУЧАК

Мождани удар представља један од најчешћих узрока смртности и инвалидитета у свету, са великим утицајем на појединце и друштво у целини. Савремене технологије, посебно машинско учење, омогућавају развој модела који могу ефикасно предвидети појаву овог обољења на основу различитих фактора ризика као што су старост, хипертензија, срчана обољења итд. У овом истраживању анализирани су и примењени различити алгоритми машинског учења укључујући логистичку регресију, *KNN*, стабла одлуке, *Random Forest* и *SVM*, с циљем да се идентификује модел који пружа најпоузданије резултате у предикцији можданог удара.

Резултати истраживања показали су да *Random Forest* пружа најбоље перформансе у смислу прецизности, одзива и F1-мере, што је чини најпоузданијим моделом за предикцију овог обољења. Њена способност да постигне баланс између тачних предвиђања и минимизације лажно позитивних резултата чини је веома корисном у медицинским истраживањима. Алгоритми као што су *SVM* и *KNN* такође су показали значајан ниво тачности, али су у крајњој оцени заостали за *Random Forest*-ом.

Логистичка регресија, као најједноставнији модел, остварила је најслабије резултате, што указује на потребу за применом сложенијих и напреднијих алгоритама у области предикције можданог удара. Резултати овог истраживања показују да примена машинског учења у медицини може значајно побољшати рану дијагностику и превенцију можданог удара, што би допринело ефикаснијем здравственом збрињавању и смањењу ризика од смртних исхода.

Будућа истраживања могла би се усмерити на унапређивање постојећих модела уз финансијску оптимизацију хиперпараметара и примене неких напреднијих модела машинског учења попут неуронских мрежа, чиме би се потенцијално постигао још виши ниво поузданости у предвиђању можданог удара. Такође, радом на квалитету и обиму прикупљених података, доприноси се значајном побољшању крајњих резултата. Такав приступ би омогућио дубљу анализу и тачније откривање суптилних образаца, што би на крају довело до развоја напреднијих стратегија за превенцију и значајно смањење ризика од појаве можданог удара.

ЛИТЕРАТУРА

- [1] Moumita Ghosh, A. Thirugnanam, *Introduction to Artificial Intelligence*, 2021
- [2] Satish Dhokare, Dr. Arun Gaikwad, *A Study of Artificial Intelligence: Types, Opportunities & Challenges*, 2021
- Датум приступања 09.08.2024
- [3] <https://www.soci.ai/knowledge-articles/branches-of-artificial-intelligence/>
- [4] Andrew Ng, *Coursera: Machine Learning Specialization*
- [5] Andrew Ng, Tengyu Ma, *CS229 Lecture Notes*, June 11 2023
- [6] Anđelka Milovanović, *Mašinsko učenje*, Tehničko i naučno pisanje, Matematički fakultet
- [7] Alex Smola, S.V.N. Vishwanathan, *Introduction to Machine Learning*, Cambridge University Press, 2008
- [8] Amer F.A.H. Alnuaimi and Tasnim H.K. Albaldawi, *An overview of machine learning classification techniques*, College of Science, University of Baghdad, Iraq, April 2024
- [9] Dritsas E, Trigka M, *Stroke Risk Prediction with Machine Learning Techniques*, Sensors 2022

Датум приступања 24.06.2024

- [10] <https://www.kaggle.com/datasets/fedesoriano/stroke-prediction-dataset?resource=download>
- [11] Manisha Sanjay Sirsat, Eduardo Ferme, Joana Camara, *Machine Learning for Brain Stroke: A Review*, 2020
- [12] Shoily, T.I.; Islam, T.; Jannat, S.; Tanna, S.A.; Alif, T.M.; Ema, R.R. *Detection of stroke disease using machine learning algorithms*, Department of Computer Science and Engineering, North Western University, Khulna, Bangladesh, 6-8 July 2019
- [13] Sailasya G, Kumari G.L.A, *Analyzing the performance of stroke prediction using ML classification algorithms*. Int. J. Adv. Comput. Sci. Appl. 2021
- [14] Pradeepa S, Manjula K, Vimal S, Khan M.S, Chilamkurti N, Luhach A.K, *DRFS: Detecting risk factor of stroke disease from social media using machine learning techniques*, Neural Process. Lett. 2020

Датум приступања 05.09.2024

- [15] <https://medium.com/@johnnaujoks/adventures-in-cross-validation-techniques-with-linear-regression-models-75f4e30471>

Датум приступања 05.09.2024

- [16] <https://www.nhlbi.nih.gov/health/stroke>

Датум приступања 05.09.2024

- [17] <https://www.stroke.org/en/about-stroke>

Датум приступања 05.09.2024

- [18] <https://www.mayoclinic.org/diseases-conditions/stroke/symptoms-causes/syc-20350113>

Датум приступања 06.09.2024

- [19] <https://www.betterhealth.vic.gov.au/health/conditionsandtreatments/effects-of-stroke>

Датум приступања 15.09.2024

- [20] <https://hanj.cs.illinois.edu/cs412/bk3/03.pdf>

Датум приступања 16.09.2024

- [21] <https://www.geeksforgeeks.org/k-nearest-neighbours/>

Датум приступања 16.09.2024

- [22] <https://medium.com/swlh/k-nearest-neighbor-ca2593d7a3c4>

Датум приступања 17.09.2024

- [23] <https://www.kdnuggets.com/2020/01/decision-tree-algorithm-explained.html>

- [24] <https://www.geeksforgeeks.org/decision-tree-introduction-example/>

- [25] <https://www.geeksforgeeks.org/random-forest-algorithm-in-machine-learning/>

- [26] <https://medium.com/@mrmaster907/introduction-random-forest-classification-by-example-6983d95c7b91>

- [27] <https://medium.com/@denizgunay/random-forest-af5bde5d7e1e>

Датум приступања 18.09.2024

- [28] <https://www.analyticsvidhya.com/blog/2021/07/svm-support-vector-machine-algorithm/>

- [29] <https://medium.com/@pp1222001/outlier-detection-and-removal-using-the-iqr-method-6fab2954315d>

- [30] <https://www.geeksforgeeks.org/introduction-to-anomaly-detection-with-python/>

- [31] <https://www.geeksforgeeks.org/ml-label-encoding-of-datasets-in-python/>

- [32] <https://www.geeksforgeeks.org/ml-handling-imbalanced-data-with-smote-and-near-miss-algorithm-in-python/>

- [33] <https://www.geeksforgeeks.org/confusion-matrix-machine-learning/>

Датум приступања 19.09.2024

- [34] <https://medium.com/@ankotop/applying-ai-in-your-business-2fc550b139b4>

- [35] <https://medium.com/hyunjulie/activation-functions-a-short-summary-8450c1b1d426>

- [36] <https://medium.com/@pardeshi.vishwa25/bias-variance-tradeoff-explained-7f18ebbf020>
- [37] https://www.researchgate.net/figure/Elbow-method-for-optimal-value-of-K_fig2_344027507
- [38] <https://techntales.medium.com/random-forest-a-powerful-machine-learning-algorithm-1dd65031a8ae>